



DESARROLLO DE SISTEMAS DE INTELIGENCIA ARTIFICIAL

Memoria Vectorial y Búsqueda Semántica

Del colapso del contexto estático a la
indexación con FAISS.

¿Por qué no podemos enviar el catálogo entero al LLM?



Desangre de Tokens

Enviar 500 artículos por consulta multiplica el consumo y el gasto exponencialmente (ej. 1,000 consultas = costo inviable).



Lost in the Middle

Al saturar al modelo con texto masivo, este ignora o alucina la información ubicada en el medio de la lista (ej. el artículo 347).



Estado Concurrente

El prompt se congela en la sesión. Si el inventario cambia simultáneamente en otra terminal, el LLM miente con seguridad.



Transformando texto en coordenadas espaciales



Textos con significados similares terminan en el mismo barrio geométrico, sin importar si comparten palabras exactas.



Dos paradigmas de recuperación de datos




SQL - Base Relacional

- **Mecanismo:** Coincidencia exacta de caracteres (LIKE '%fresco%').
- **Falla:** Si el usuario busca veraniego y el texto dice fresco, la base de datos devuelve cero resultados.



Naturaleza: Rígido y binario.



Embeddings - Memoria Vectorial


- **Mecanismo:** Proximidad de significado en el espacio multidimensional.
- **Ventaja:** Fresco, liviano y veraniego apuntan exactamente a la misma coordenada.



Naturaleza: Flexible y contextual.




Medir la intención, no la longitud



Insight:


La **Similitud Coseno** mide el ángulo entre dos vectores, ignorando por completo su magnitud (el largo del texto).



¿Por qué necesitamos FAISS?


Comparar una consulta contra millones de vectores uno por uno es computacionalmente inviable. FAISS (desarrollado por Meta) organiza los vectores en estructuras eficientes para encontrar vecinos cercanos al instante.

**Fuerza Bruta /
Sin Índice - $O(N)$**



$O(N)$

**Búsqueda con
Índice FAISS**



$O(\log N)$

Para catálogos pequeños (< 10,000 ítems) usamos **IndexFlatL2**: búsqueda exacta sin aproximaciones.



Separando el Significado de la Lógica

The Semantic Brain


"descripcion_semantica":

Texto rico: sinónimos, texturas, usos y tacto (ej. 40+ palabras).

The Logical Filter

"metadatos":

Datos duros: **en_stock**: True, sucursal: Córdoba.



Destino:

Se transforma en Vector.



Destino:

Filtro relacional.

Insight: La calidad de la búsqueda depende directamente de la riqueza descriptiva del campo semántico.



Arquitectura de Ejecución (Pipeline Vectorial)

Memoria Vectorial Externa en acción: recuperamos solo lo necesario y maximizamos la precisión, eliminando el colapso del contexto.




Los límites arquitectónicos de FAISS en Producción

Volatilidad. Almacena en archivos binarios frágiles. Sin `faiss.write_index()`, la memoria RAM se borra al reiniciar.

Sin Filtrado Híbrido. No puede cruzar vectores con metadatos nativamente (ej. buscar tela suave Y en stock).

Sin Concurrencia. El índice se corrompe si múltiples procesos intentan escribir datos al mismo tiempo.



**ChromaDB
(Clase 5)**

Síntesis de la Clase y Próximos Pasos



La Memoria Vectorial externa resuelve la amnesia del LLM y el límite de tokens.



Los embeddings mapean textos por significado, superando la rigidez de SQL.



La Similitud Coseno evalúa intención midiendo ángulos, no magnitudes.



FAISS es un motor de indexación potente, pero requiere migración para filtrado híbrido.

Tarea Asincrónica

1. Generar JSON con 15 telas (incluyendo descripcion_semantica y metadatos).
2. Diseñar flujograma híbrido en Mermaid.
3. Redactar 3 Killer Queries (prueba de estrés).



[Escanear para consigna]

